

## RAPPORT DU PROJET COMPILATION

### Thème

Utilisation de LEX et YACC pour l'évaluation et génération d'une  
forme intermédiaire d'une expression arithmétique

#### Réalisé par

- TAKLIT ZINA
- OPTION SIL

#### Encadré par

- MR AIT AOUDIA

Promotion : 2017/2018

# Sommaire

Sommaire .....	2
Introduction et problématique .....	4
Partie Evaluation : .....	6
Analyse lexicale : .....	7
Mise en œuvre : .....	7
Analyse syntaxique : .....	8
Mise en œuvre : .....	8
Ccalc.h : .....	11
eval.c : .....	12
ccalc.c : .....	13
Exemple d'évaluation : .....	13
La gestion des erreurs : .....	14
Processus de gestion des erreurs : .....	14
Exemple de messages d'erreurs significatifs : .....	16
Partie code Intermédiaire : .....	16
Mise en œuvre : .....	17
Générer les Quad correspondants aux opérations : .....	18
L'évaluation : .....	24
Exemple de fonction d'interprétation : .....	25
Affectation : .....	25
Addition : .....	25
JZ : .....	25
JMP : .....	26
JG : .....	26
JL : .....	26
Load : .....	26
Exemple de code intermédiaire et d'évaluation : .....	27
Fonctions de base : .....	27
Puissance : .....	27
Somme : .....	27
Somme imbriqué : .....	28


Moyenne pondérée : .....	28
Variance : .....	29
Ecart type : .....	29
Max Min : .....	30
Autre exemple : .....	30
Conclusion.....	32
Bibliographie .....	33

# Introduction et problématique

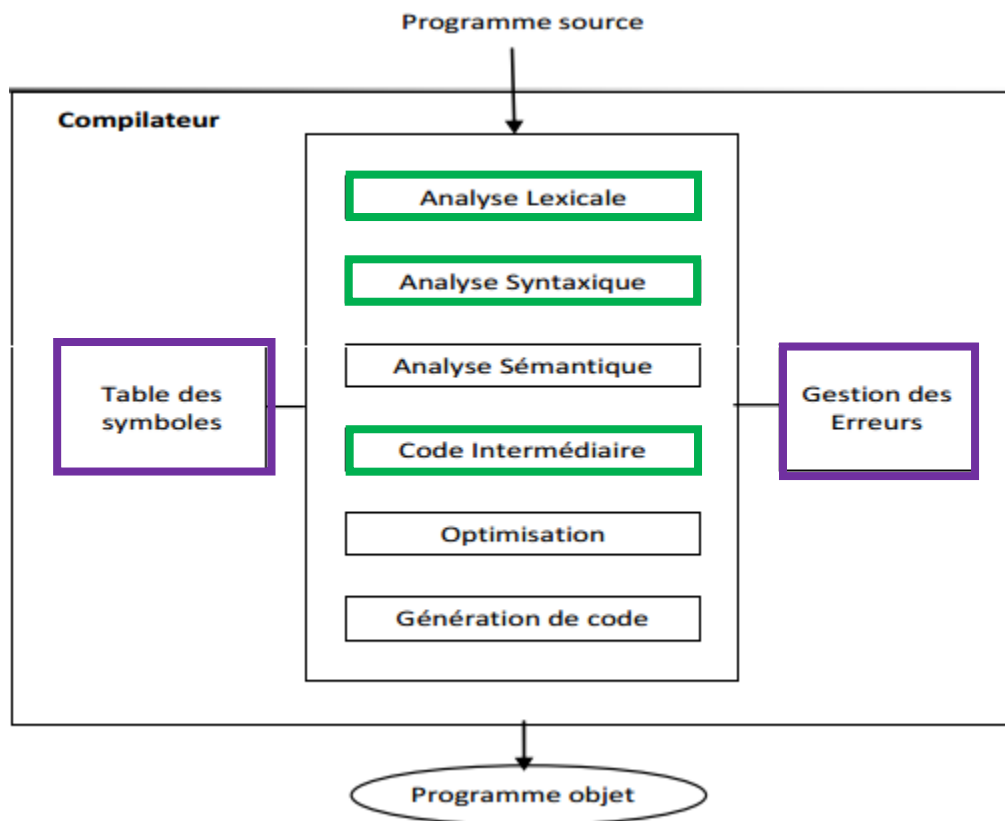
Un compilateur désigne un programme qui permet de transformer un code source écrit dans un langage de programmation (langage source) en un autre langage informatique (appelé langage cible) qui peut être exploité par la machine après. Donc :

Compilateur = **vérification** et **traducteur**

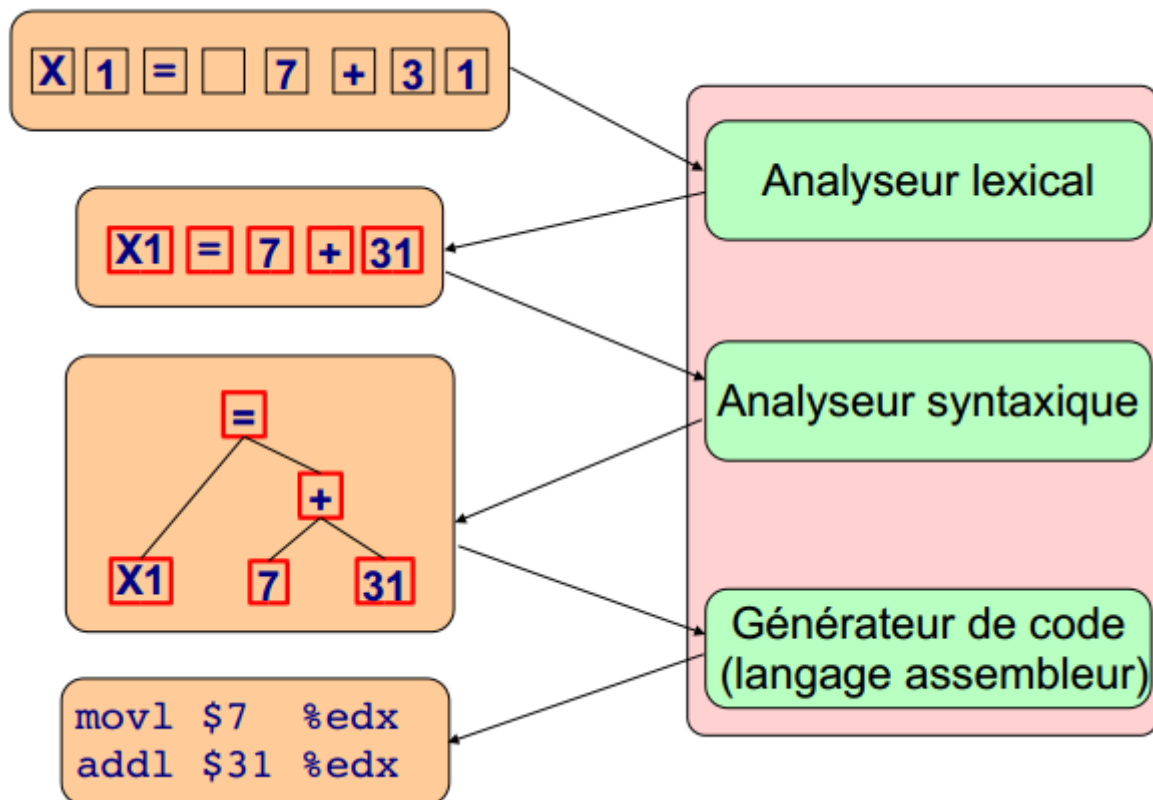
Voici un schéma qui montre le rôle d'un compilateur :



La compilation passe par plusieurs étapes afin d'aboutir un programme objet comme on peut la voir dans cette illustration :



A considérer qu'il y a trois (3) étapes les plus importantes dans la compilation : Analyse lexical, analyse syntaxique, et génération de code. Et pour avoir une idée générale sur ces trois étapes voici ce schéma qui donne un exemple sur chaque étape :



Notre Tp jete la lumière sur ces trois étapes afin de simuler le fonction d'un vraie compilateur :

- Dans la première partie on va développer un analyseur syntaxique d'un expression arithmétique en utilisant LEX et YACC. Les opérandes sont des des nombres entiers ou flottants. Dans cette partie en va aussi signalées les erreur syntaxique et lexical avec un message significatifs au cas d'un erreur.
- Dans la 2<sup>ème</sup> partie qui consiste a compléter le travail de la première partie pour évaluer l'expression arithmétique donné en entrée si dernière est syntaxiquement correcte. Tout en ajoutant des fonction qui sont souvent utilisées dans les évaluateurs (moyen pondérer).
- La 3<sup>ème</sup> parties et comme les opérandes ne sont pas connus durant la phase de compilation et donc on va générer une forme intermédiaire sous forme de quadruplets qui une fois exécuté donnera le résultat de l'expression donné au départ.

On utilise Flex comme générateur d'analyse syntaxique et Bison comme générateur d'analyse lexical, et comme la partie une est commune pour les 2 dernière partie donc on va diviser notre travail en 2 grand partie :

1. Partie Evaluation qui contien ces fichier :
  - Ccalc.c : contient la fonction main et les fonctions nécessaire pour les différentes affichage et les fonctions nécessaires pour la gestion erreurs.
  - Ccalc.h : Définition incluse pour tous les modules.
  - Eval.c : contien les fonctions basique et d'autre fonction souvent implémenter pour les évaluateurs.
  - Yacc.y :Grammaire d'entrée pour Bison.
  - Lex.l :Entrée pour Flex.
  - In.txt : contient la fonction à évaluer.
2. Parite code intermédiaire :

## Partie Evaluation :

Les fichiers ccalc.c, ccalc.h, lex.l, et yacc.y sont presque les mêmes à ceux du partie évaluation avec des petit modif selon les fonctions implémenté.

- Interm.c : contien les fonctions nécessaires pour générer la forme intermédiaire.
- Evaluation.c : permet d'évaluer et d'écuté les forme interrmédiaire générées.
- In.t : contient l'exprssion dont on va générer son code intermédiaire.
- Out.txt : le code intermédiaire générer pour l'expression du départ.

## Partie Evaluation :

Certains traitement dise action sémantique (routine sémantique) sont effectué au fur et à mesure que se d'éroule l'analyse syntaxique. On appelle ça une traduction dériver par la syntaxe qui peut avoir plusieurs forme :

pour les évaluateurs d'expression, tel MS EXCEL, le résultat sera l'évaluation de l'expression mathématique si celle-ci est syntaxiquement correcte.

## Analyse lexicale :

L'analyse lexical fait partie de la première phase de la chaîne de compilation. Elle consiste à convertir une chaîne de caractère en une liste de symboles (Tokens). Ces Tokens seront utilisés pendant l'analyse syntaxique.

Lex, Flex sont parmi les logiciels qui construisent automatiquement un analyseur lexical.

### Mise en œuvre :

Pour atteindre le but de cette phase on a créé un fichier « lex.l » qui permet de reconnaître :

- Identificateur « les variables » (a,b,c...).
- Les nombres flottants (Float) : 2. 5...
- Les noms de différentes fonctions utilisés dans le TP : « som » (somme) , « moy » (moyenne), « var » (variance) , « ecr » (ecart type), « max » , « min » .
- Les espaces « whitespace » ; les caractères séparant entre les unités lexicales. Les espaces sont reconnus mais non retournés à l'analyseur syntaxique.
- Tout autres caractères ne sont pas respectés.

Voici une image qui montre comment est structuré ce fichier :

```
1 %option noyywrap
2 %{
3     #include <stdio.h>
4     #include <stdlib.h>
5     #include <ctype.h>
6     #include "ccalc.h"
7     #include "yacc.tab.h"
8
9     #define YY_INPUT(buf,result,max_
10     result = GetNextChar(buf, max_
11     if ( result <= 0 ) \
12     result = YY_NULL; \
13 }
14 %}
15 [D [ a-zA-Z][ a-zA-Z0-9]*
16 %%
```

Inclure `yacc.tab.h` pour permettre de récupérer les Tokens avec `yyval`

Pour la gestion des erreurs plus tard

Les variables permises : a, b, a1...

```
17 som {yyval.fcc=1; return fc;}
18 moy {yyval.fcc=2; return fc;}
19 min {yyval.fcc=3; return fc;}
20 max {yyval.fcc=4; return fc;}
21 var {yyval.fcc=5; return fc;}
22 ecr {yyval.fcc=6; return fc;}
23 SI {yyval.fcc=7; return fc;}
24
25 [0-9]+\.[0-9]+ {
26     BeginToken(yytext);
27     yyval.v=atof(yytext); return nb;
28 }
29
```

Reconnaissance de fonctions

Reconnaissance des nombres flottants

```
30 {ID} {
31     BeginToken(yytext);
32     yylval.string = malloc(strlen(yytext));
33     strcpy(yylval.string, yytext);
34     return IDENTIFIER;
35 }
36 [ \t\r\n]+ {
37     /* eat up whitespace */
38     BeginToken(yytext);
39 }
40 . { BeginToken(yytext);
41     return yytext[0]; }
42 %%
43
```

Reconnaissance des différentes variables

Reconnaître les espaces et les échapper

Tout autres caractères ne sont pas respectés

## Analyse syntaxique :

L'analyseur syntaxique (parser en anglais) est le programme informatique qui consiste à vérifier si la grammaire fixée reconnaît le programme source donné et puis si oui la question sera comment trouver efficacement un arbre de dérivation pour ce mot (programme) donné.

Parmi les logiciels qui permettent de construire automatiquement un analyseur syntaxique on trouve Yacc, Bison... On décrit la grammaire en spécifiant :

- Ses terminaux (ou lexème)
- Ses règles.

Et on associe à chaque règle une action qui sera exécutée lors de la réduction.

## Mise en œuvre :

*Yacc.y :*

Ce fichier contient les définitions des variables et les appels aux fonctions nécessaires dans cette partie. Les déclarations nécessaires dans ce fichier sont les suivantes :

- Bloc littéral optionnelle pour les déclarations C :

```
%{ //déclaration C %}
```

👉 Il faut inclure la bibliothèque `ccalc.h` pour les appels de fonctions nécessaires.

```
14 %{
15 #include <ctype.h>
16 #include <stdlib.h>
17 #include <stdio.h>
18 #include <string.h>
19 #include "ccalc.h"
20 #define YYERROR_VERBOSE 1
21 static Variable *ID; //Global variable
22 %}
```

- Une directive union décrivant les types des valeurs associées aux symboles terminaux et non terminaux :



```
%union { //déclaration associé}
```

- ☞ La structure « list » est utilisée pour sauvegarder les valeurs d'une liste dans un tableau, afin d'appliquer des traitements plus tard tel le calcul de la moyenne pondérée.

```
%union {  
    float v; // The float values  
    char *string; // refers to IDs  
    int fcc; // The function : som, moy, max, min...  
  
    struct { // Struct of list  
        // float value;  
        float values[15];  
        int cpt;  
    } list;  
}
```

- Déclaration des terminaux ayant un nom :

```
%token <NOM> nom_terminal
```

- ☞ Le terminal « nb » est de type : float. A noter que « nb » est le token retourné par l'analyse lexical.

```
%token <v> nb
```

- Déclaration de symboles non terminaux, enrichis de leurs types :

```
%type <NOM> nom_non_terminal
```

- ☞ Les non terminaux « E » et « fct » sont de type : float.
- ☞ Le non terminal « L » est de type : list.
- ☞ Le non terminal « nf » (nom de la fonction) est de type : int.

```
%type <v> E fct  
%type <list> L  
%type <fcc> nf
```

A noter qu'il faut déclarer tous les terminaux et non terminaux avec les directives « token » respectivement « type », sinon un message d'erreur sera signalé par exemple :

```
warning Y4003: '$3': attribute is untyped
```

- Priorisation des opérateurs en considérant leurs associativités :

```
%left 'symbole1' 'symbole2' ...  
%right 'symbol3' 'symbol4' ...
```

- ☞ Les opérateurs binaires « - » et « + » sont associatifs à gauches.
- ☞ Les opérateurs binaires « \* » et « / » sont associatifs à droites.
- ☞ L'opérateur unaire « - » est associatif à droite.
- ☞ Pour la priorité des opérateurs les plus prioritaires sont écrits le plus bas.

```
%left '-' '+'  
%left '*' '/'  
%right '^'  
%left '>' '<' '='  
%right moins_unaire
```

- Déclaration (optionnelle) du symbole de départ :

%start <NOM>

```
50 %start program
```

- Un ensemble de règles est donné sous la forme :

```
<non terminal> : <membre droit1>
                | <membre droit2>
                .....
                ;
```

- ☞ Le programme est formé d'un ensemble d'instructions séparer « ; ».

```
53 //Rules
54 program
55 : statement ';' program
56 | statement ';'
57 | statement error ';' program
58 {
59   yyerrok;
60 }
61 ;
```

- ☞ La forme de programme a pour but d'exécuté plusieurs instruction en même temps et d'afficher les valeurs de chaque ligne vers la fin.Ex :

a : 22+3 ;

b : moy(1,23) ;

Et donc afficher la valeurs 25 et 2 pour a respectivement b à la foi.

```
statement
: IDENTIFIER {ID = IDGet($1, &@1);}
'| E{IDsetValue(ID, $4);}
| E
;
```

- ☞ Différentes formes de l'expression « E » qui peut être la différence des deux expressions ou leurs additions ou un nombre ou ...

```
75 E : E '-' E {
76   $$ = Sub($1, $3);
77 }
```

```
100 | '-' E %prec moins_unaire {$$=-$2;}
101 | '(' E ')' {$$=$2;}
102 | nb {$$=$1;}
103 | fct {$$=$1;}
104 | IDENTIFIER {$$ = IDGetValue($1, &@1);}
105 ;
```

- ☞ L'expression peut être aussi un appel à une fonction (som, moy ...) « nf » refera au nom de la fonction ex : 1 pour la somme et 2 pour la moyenne pondérer ... som(1,2,3,4) dans ce cas nf=1(sommer les éléments de la liste) et \$\$=10 (la valeurs retourner par la fonction « Sum »).

```
107      fct: nf '(' L ')'  
108      {  
109          switch($1)  
110          {  
111              case 1:  
112                  $$=Sum($3.values,$3.cpt);  
113                  break;  
114              case 2:  
115                  $$=Moy($3.values,$3.cpt);  
116                  break;
```

- ☞ La liste « L » peut être un ensemble d'éléments « E » et/ou d'autres liste « L ». On sauvegarde les éléments de chaque liste « L » dans un tableau afin de l'utiliser plus tard.

```
138      L : L ',' E {  
139          $$=$1; $$.values[$$.cpt++]=$3;  
140      }  
141      | E {  
142          $$.values[0]=$1;  $$.cpt=1;}  
143      ;  
144      %%
```

Voici un exemple de l'appelle à une fonction :

```
75      E : E '-' E {  
76          $$ = Sub($1, $3);  
77      }
```

Dans cette règle l'appelle au fonction « Sub » permet d'affecté le résultat de la différence des deux expressions à droite (\$1 et \$2) à l'expression qui se trouve à gauche (\$\$).

Voici d'autre fichier qui permet de mener cette évaluation :

## Ccalc.h :

Ce fichier contient :

- Déclaration nécessaire et la structures de variable qui permet de sauvegarder la valeur de chaque instruction afin de les afficher plus tard.

```
13  #include "yacc.tab.h"  
14  
15  // Functions of lex & yacc  
16  extern int yylex(void);  
17  extern int yyparse(void);  
18  extern void yyerror(char*);  
19  
20  typedef struct _Variable {  
21      char    *name;  
22      float  value;  
23  } Variable;
```

- L'ensemble des fonctions implémenter pour ce Tp.
- Les fonctions qui permet de lire les instructions de programme depuis un fichiers.

- Les fonctions qui permet de gérer les erreurs.
- Les fonctions qui permet de gérer manipuler les différent IDS ainsi qu'afficher leurs valeurs vers la fin.

```
25 // Functions of TP
26 extern float SI(float values[15]);
27 extern float Ecrt(float [15],int);
28 extern float Var(float [15],int);
29 extern float Moy(float [15],int);
30 extern float Sum(float [15],int);
31 extern float Max(float [15],int);
32 extern float Min(float [15],int);
33 extern float Pow(float, float);
34 extern float Add(float, float);
35 extern float Sub(float, float);
36 extern float Mult(float, float);
37 extern float Div(float, float, YYLTYPE*);
38
39 //Need it for the final display and to print significant errors
40 extern void DisplayLine(void);
41 extern int GetNextChar(char *b, int maxBuffer);
42 extern void BeginToken(char*);
43 extern void PrintError(char *s, ...);
44
45 //To manipulate the deferent IDs
46 extern Variable *IDGet(char*, YYLTYPE*);
47 extern void IDsetValue(Variable*, float);
48 extern float IDGetValue(char*, YYLTYPE*);
49 extern void DisplayAllIDs();
50
51 #endif /*CCALC_H_*/
```

## eval.c :

- Une bonne pratique est de séparer toutes les fonctions dans un fichier appart. Voici un exemple d'une fonction basique « Add » qui permet de faire la somme de deux nombres.

```
81 float Add(float a, float b) {
82     return a + b;
83 }
```

Une autre fonction qui permet de calculer la moyens pondérée d'une liste donné sous forme d'un tableau :

```
39 float Moy( float values[15],int cpt)
40 {
41     float moy=0;
42     moy = (Sum(values,cpt)/cpt);
43     return moy;
44 }
```

Cette fonction ci-dessous permet de calculer la variance des éléments de la liste :

```
26 float Var( float values[15],int cpt) {
27     //vriance (n1,n2,n3,...,n)=(n1-moy(n1...n)carré+n2-moy(n2...n)carré+...)/n-1
28     float variance=0;
29     float moy=Moy(values,cpt);
30     for (int j=0;j<cpt;j++)
31         variance+=pow((values[j]-moy),2);
32     return (variance/(cpt));
33 }
```

## ccalc.c :

On se concentre ici sur la fonction main qui fait appel à la fonction getNextLine() qui permet de lire les données de fichier ligne par ligne et puis exécuté la fonction yyparse() qui permet de faire l'analyse syntaxique et qui fait un appel implicite au fonction yylex() qui fait l'analyse lexical. Enfin l'appelle au fonction DisplayAllIDs() qui permet d'afficher le contenu de l'évaluation de chaque ligne :

```
203 int main() {
204     //int i;
205     char *infile=NULL;
206     printf("===== Evaluation ===== \n\n");
207     infile = "in.txt";
208     file = fopen(infile, "r");
209     if ( file == NULL ) {
210         printf("cannot open input\n");
211         return 12;
212     }
213     buffer = malloc(MaxBuff);
214     if ( buffer == NULL ) {
215         printf("cannot allocate %d bytes of memory\n", MaxBuff);
216         fclose(file);
217         return 12;
218     }
219     DisplayLine();//Display the read line
220     if ( getNextLine() == 0 )
221         yyparse();
222     free(buffer);
223     fclose(file);
224     printf("final content of variables\n");
225     DisplayAllIDs();
226     return 0;
227 }
```

## Exemple d'évaluation :

A noter que pour que générer l'exécutable il faut exécuter ces instructions :

- flex lex.l
- bison -d yacc.y
- gcc -std=c99 -o tp ccalc.c yacc.tab.c lex.yy.c -lm

Voici un exemple d'évaluation :

La gestion des erreurs :

```
1 a:2+5*3-(2+6);
2 b:som(2,3,5,6,8);
3 c:moy(1,2,3);
4 d: 5 + 3 * som(4, som(5,7,8), var(1,1+1, moy(2,4),4,6-2));
5 e:max(3,4,max(8,3));
6 f:min(10,5,max(2,3));
7 g:ecr(3,5,6,8,9);
8 h:3^3;
```

Qui donne comme résultats :

```
===== Evaluation =====

1 |a:2+5*3-(2+6);
2 |b:som(2,3,5,6,8);
3 |c:moy(1,2,3);
4 |d: 5 + 3 * som(4, som(5,7,8), var(1,1+1, moy(2,4),4,6-2));
5 |e:max(3,4,max(8,3));
6 |f:min(10,5,max(2,3));
7 |g:ecr(3,5,6,8,9);
8 |h:3^3;final content of variables
ID----- Value-----
'a          ' 9
'b          ' 24
'c          ' 2
'd          ' 81.08
'e          ' 8
'f          ' 3
'g          ' 2.13542
'h          ' 27
```

## La gestion des erreurs :

La fonction qui permet d'afficher des erreurs significatives est utilisée par les 2 parties. On la prend plus en détails de cette section afin de montrer l'utilité d'afficher des erreurs significatives qui peuvent après aider pour déboguer :

Processus de gestion des erreurs :

- ☞ Pour afficher des messages d'erreurs significatifs on utilise la macro : `YYERROR_VERBOSE` et donc le premier message d'erreurs 'syntax error' va devenir :

```
Error 'syntax error, unexpected IDENTIFIER, expecting SEMICOLON'
```

- ☞ Flex possède aussi la macro `YY_INPUT` qui lit les données pour l'interprétation de « token ». Donc on ajoute un appel dans `YY_INPUT` à la fonction `GetNextChar()` qui lit les données de fichier et sauvegarde l'information sur la position du caractère suivant à lire en utilisant un buffer qui va contenir une ligne du fichier. Voici comment est utilisée la macro `YY_INPUT` dans notre TP :

La gestion des erreurs :

```
#define YY_INPUT(buf,result,max_size) {\n    result = GetNextChar(buf, max_size); \n    if ( result <= 0 ) \n        result = YY_NULL; \n}
```

- ☞ La fonction `BeginToken()` est appelé par chaque règle pour rappeler le début et la fin de chaque jeton. Voici un exemple d'utilisation de cette fonction :

```
[0-9]+|[0-9]*\.[0-9]+ {\n    BeginToken(yytext);\n    yylval.v=atof(yytext);return nb;\n}
```

- ☞ La fonction `PrintError()` est appelé à chaque fois qu'il y a une erreur pour afficher un message d'erreur sophistiqué.
- ☞ Lorsque on a plusieurs erreurs qui sont commis en même temps dans la même ligne on est besoins de la position de l'expression pour y faire on mit la position exacte du « token » dans la variable global « `yyloc` » de type `YYLTYPE`. Ensemble avec la macro `YYLOC_DEFAULT`, Bison calcule la position de l'expression. La version par défaut de `YYLTYPE` est :

```
typedef struct YYLTYPE\n{\n    int first_line;\n    int first_column;\n    int last_line;\n    int last_column;\n} YYLTYPE ;
```

Mais elle peut être redéfinie pour ajouter d'autre informations.

Les différent champs de la structure `YYLTYPE` sont mis à jours à chaque appelle de la fonction `BeginToken()` :

```
//Mark the beginig of new token\nextern void BeginToken(char *t) {\n    /* remember last read token ----- */\n    StartToken = NextStartToken;\n    TokenSize = strlen(t);\n    NextStartToken = cptBuffer; // + 1;\n    /* location for bison ----- */\n    yyloc.first_line = NumLine;\n    yyloc.first_column = StartToken;\n    yyloc.last_line = NumLine;\n    yyloc.last_column = StartToken + TokenSize - 1;\n}
```

Sauvegarder le dernier token lit.

Mettre à jours la position exacte de l'expression.

- ☞ Pour les règles pour utiliser la position « location » il faut étendre la règle et ceci pour éviter de copier toute la structure dans la règle, un pointeur est généré. Pour l'emplacement du token `$3` est référencé via `@3` est le pointeur générer est `&@3`.

```
| E '/' E {\n    $$ = Div($1, $3, &@3);\n}
```

## Partie code Intermédiaire :

- ☞ Pour les fonction les champs de YYLTYPE sont mis à jour directement pour chaque erreur détecter, comme on peut l'avoir dans la fonction qui traite la division entre deux nombres, les champs de YYLTYP sont mis à jour directement au cas où le second membre égale à « 0 ».

```
//divide two numbers, check for zero
extern float Div(float a, float b, YYLTYPE *bloc) {
    if ( b == 0 ) {
        PrintError("division by zero! Line %d:c%d to %d:c%d",
                  bloc->first_line, bloc->first_column,
                  bloc->last_line, bloc->last_column);
        return FLT_MAX;
    }
    return a / b;
}
```

Exemple de messages d'erreurs significatifs :

```
a:2/0;
b:2+3();
c:som(2,3,);
d:min(max);
f:var(2,3;
g!!!!mp;
```

```
===== Evaluation =====

1 |a:2/0;
..... !.....^ token6:6
Error: division by zero! Line 1:c4 to 1:c4
2 |b:2+3();
..... !.....^.. token6:6
Error: syntax error, unexpected '(', expecting ';'
3 |c:som(2,3,);
..... !.....^.. token10:10
Error: syntax error, unexpected ')'
4 |d:min(max);
..... !.....^..... token6:6
Error: syntax error, unexpected ')', expecting '('
5 |f:var(2,3;
..... !.....^..... token10:10
Error: syntax error, unexpected ';', expecting ')' or ','
6 |g!!!!mp;
..... !.^..... token2:2
Error: Reference to unknown variable '(null)'
```

## Partie code Intermédiaire :

La forme intermédiaire est une abstraction du programme source qui peut être un arbre abstrait (AST for Abstract Syntax Tree) ou un code à trois adresse (quadruplets, triples). La forme intermédiaire est indépendante de la machine et donc elle n'est pas liée à ses jeux d'instruction et est facile de transformer le code intermédiaire au code machine. Une optimisation du code peut s'effectuer à ce niveau-là avant de générer le code objet final. Dans



notre Tp on a opté pour le 2<sup>ème</sup> choix, code à trois (3) adresse qui est le plus utilisé et plus proche du jeu d'instruction de la machine, et on va utiliser les quadruplets pour représenter la forme intermédiaire.

La structure du Quadruplet est de la forme : (op, source1, source2, destination). La source1, source2 et destination sont des variables, constantes ou variables temporaire générés par le compilateur. Op représente un opérateur tel un opérateur arithmétique ou un branchement. Le résultat de l'opération effectué entre la source1 et source2 et assigné aux destinations comme ceci : destination = source1 op source2.

### Mise en œuvre :

Structure et fonction essentiel pour générer QuadrUplet :

- Structure « Variable » qui contient le nom de la variable et sa valeur (la valeur sera utilisé pour la partie évaluation).

```
typedef struct _Variable {  
    char    *name;  
    float   value;  
} Variable;
```

- Tableau IDS qui contient l'ensemble des variables déclaré par l'utilisateur, avec un compteur qui permet de parcourir cette table :

```
static Variable IDs[100];  
static int cptIDs;
```

- Tableau Tmps qui contient les variables temporaires générer pendant la traduction, avec un compteur qui permet de parcourir cette table :

```
static Variable Tmps[200];  
static int cptTmps;
```

- Fichier « out » là où on va écrire les quadruplets générer.
- Une variable « NumLine » qui est incrémenter à chaque fois qu'une écriture sur le fichier est effectué et ça sert pour générer les « Jump » après.

```
static int NumLine;
```

- La fonction « WriteQuad » qui permet d'écrire directement les quadruplets générer dans le fichier « out ».

```
// To generate Quad And put it in the file Out  
extern void WriteQuad(char *opCode, char *src1, char *src2, char *dest)  
{  
    char *cmd=malloc(50);  
    sprintf(cmd, "%s %s %s %s\n", opCode, src1, src2, dest);  
    fputs(cmd, file);  
    free(cmd);  
    NumLine++;  
}
```

Le fichier « lex » est le meme que celui utilisé dans la partie évaluation. Pour le fichier « yacc » qui contient l'ensmble de déclaration et de règle pour l'analyse lexical la différence avec celui de la partie écaluation est :

- Dans cette partie on évlaue pas, tout ce qu'on fait est la gestion de code intermédiaire correspondant aux entrées donc ce qui va etres manipuler est les variables et les tmps et donc le type des expression change ainssi que le type des élément de la liste :

```
%type <string> E fct
```

`%type <list> L`

- Pour chaque opération dans cette partie on génère un code intermédiaire au lieu d'évaluer, dans cet exemple l'appel à la fonction « Mul » permet de générer le code intermédiaire correspondant à la fonction de multiplication et retourner le temps généré pour ça :

```
| E '*' E {
  $$ = Mul($1, $3);
}
```

Générer les Quad correspondants aux opérations :

*Affectation :*

```
: IDENTIFIER ':' E
{
  IDGet($1, &@1);
  AffQuad($1,$3);
}
```

L'affectation est opération de base donc la génération du Quad est simple :

- Vérifier si la variable existe dans ce cas on génère le Quad.
  - sinon on crée d'abord la variable puis générer le Quad :
- voici le contenu de différents champs du Quad :

Op	Source1	Source2	Destination
=	\$3	#	\$1

Et voici la fonction qui permet de générer ce Quad :

```
//Generate The Quad and tmp for Affectation
extern void AffQuad(char *dest,char *src)
{
  if(idIndex(dest,0)==-1){
    IDs[cptIDs].name=dest;
    cptIDs++;
  }
  WriteQuad("=",src,"#",dest);
}
```

*L'Addition :*

```
E
: E '+' E {
  $$= Add($1,$3);
}
```

L'addition est aussi une fonction de base, la génération du Quad est aussi simple :

- Créer une variable tmpi.
- Le résultat de l'addition sera dans ce tmpi.
- Retourner le tmp généré : \$\$=tmpi.

Voici le contenu des différents champs du Quad pour cette opération :

Op	Source1	Source2	Destination
+	\$1	\$3	tmpi

Et voici la fonction qui permet de générer ce Quad :

```
//Add 2 numbers
extern
char* Add(char * a, char * b) {
    Tmps[cptTmps].name=malloc(12);
    sprintf(Tmps[cptTmps].name,"tmp%d",cptTmps+1);
    WriteQuad("+",a,b,Tmps[cptTmps].name);
    cptTmps++;
    return Tmps[cptTmps-1].name;
}
```

A noter que les autres opérations de base tel : la soustraction, multiplication, division, le moins unaire se génère de la même façon. Pour le moins unaire c'est juste qu'on pas la source2 donc à sa place on mit « # ».

*Somme d'une liste d'éléments :*

```
fct: nf '(' L ') '
{
    switch($1)
    {
        case 1:
            $$=Sum($3.values,$3.cpt);
            break;
    }
}
```

- On génère un tmp initialiser à 0.

Op	Source1	Source2	Destination
=	0	#	tmpi

- On parcourt le tableau est on ajoute chaque élément du tableau « values » tmpi générer.

Op	Source1	Source2	Destination
+	tmpi	Values[i]	tmpi

- Retourner le tmp générer : \$\$=tmpi.

Voici la fonction qui permet de générer les Quads de cette opération :

```
extern char* Sum( char* values[50],int cpt)
{
    int i=0;
    Tmps[cptTmps].name=malloc(12);
    sprintf(Tmps[cptTmps].name,"tmp%d",cptTmps+1);
    WriteQuad("=",values[i],"#",Tmps[cptTmps].name);
    for (i=1;i<cpt;i++)
    {
        WriteQuad("+",Tmps[cptTmps].name,values[i],Tmps[cptTmps].name);
    }
    cptTmps++;
    return Tmps[cptTmps-1].name;
}
```

*La moyenne pondérée :*

```
case 2:
    $$=Moy($3.values,$3.cpt);
    break;
```

La moyenne est basée sur la somme des éléments d'une liste :

- Générer les Quad correspondants a la somme des éléments d'une liste.
- Générer le Quad correspondants à la division du tmp<sub>i</sub> générer de l'opération de la somme avec le cpt (nombre des éléments de la table).

Op	Source1	Source2	Destination
/	tmp <sub>i</sub>	cpt	tmp <sub>i+1</sub>

- Retourner le tmp générer : \$\$=tmp<sub>i+1</sub>.

Voici la fonction qui permet de générer les Quads de cette opération :

```
char* Moy( char* values[50],int cpt)
{
    char *tmp;
    tmp=malloc(12);
    sprintf(tmp,"%d",cpt);
    //It's a same as Som here we just divide by cpt
    Sum(values,cpt);
    WriteQuad("/",Tmps[cptTmps-1].name,tmp,Tmps[cptTmps-1].name);
    cptTmps++;
    return Tmps[cptTmps-2].name;
}
```

*Puissance :*

```
| E '^' E
{
    //We have first to ensure that b is a degit
    printf("isNumeric($3) %d\n",isNumeric($3) );
    if (isNumeric($3))
        $$=Pow($1,$3); //Generate the Quad of Pow
    else
        printf("The given base is not a number\n");
}
```

Le principe ici est de multiplier la source par elle-même tanque la base est différente de zéro, et pour chaque itération on soustrait 1 de la base. Le processus se déroule comme ceci :

Partie code Intermédiaire :

1. Générer un tmpi initier avec la valeur de la source(a).
2. Générer un autre tmpi+1 qui va contenir la base.
3. Si la temp correspond à la base égale à 0 allez à fin (7).
4. Sino Multiplier le tmpi par la source(a).
5. Et soustrait 1 de la base (tmpi+1).
6. Allez à 2.
7. Fin

1	= 1 dest
2	Load b
3	Jz 7
4	* dest a dest
5	-b 1 b
6	Jmp 2
7	

Voici la fonction qui permet de générer les Quads de cette opération :

```
char* Pow(char * a, char * b) {
    Tmps[cptTmps].name=malloc(12);
    sprintf(Tmps[cptTmps].name,"tmp%d",cptTmps+1);//The tmp for the dest

    Tmps[cptTmps+1].name=malloc(12);
    sprintf(Tmps[cptTmps+1].name,"tmp%d",cptTmps+2);

    //We affecte the value of the b to the generate tmp
    WriteQuad("=",b,"#",Tmps[cptTmps+1].name);

    WriteQuad("=", "1", "#", Tmps[cptTmps].name);
    WriteQuad("Load",Tmps[cptTmps+1].name,"#", "#");
    char *whereJmp=malloc(12);
    sprintf(whereJmp,"%d",NumLine+5); // we are in the 2nd line and we need to jump the 7th line
    WriteQuad("JZ", "#", "#", whereJmp);
    //Maybe we need first to load the dest
    WriteQuad("=",Tmps[cptTmps].name,a,Tmps[cptTmps].name);
    WriteQuad("-",Tmps[cptTmps+1].name,"1",Tmps[cptTmps+1].name);
    sprintf(whereJmp,"%d",NumLine-3); // we are in the 5 line and we need to jum to the 2nd line
    WriteQuad("JMP", "#", "#", whereJmp);
    free(whereJmp);
    cptTmps=cptTmps+2;
    return Tmps[cptTmps-2].name;
}
```

*Racine carré<sup>1</sup> :*

Le principe utilisé pour faire cette opération et illustrait dans cette fonction :

- Définir une précision de calcul soit « n ».
- Soit « m » le résultat de l'opération de la racine carré sur le nombre donné soit « num ».
- Tanque  $m*m < num$  on ajout n à m et on itère.

```
void sqrt()
{
    float m,n; float num;
    n=0.0001;
    printf("ENTER A NUMBER : "); scanf("%f",&num);
    for(m=0;m<num;m=m+n){
        if((m*m)>num){
            m=m-n;
            break;
        }
    }
}
```

<sup>1</sup> Cette fonction permet de calculer les racine carré contenue dans l'intervalle [1, +infinie]

Pour le code intermédiaire on a qu'à traduire ce processus :

1. Générer un tmpi qui va contenir le résultat initier à 0.
2. Générer un tmpi+1 qui va contenir le la précision (tmpi+1=0.0001).
3. Soustraire la source (le nombre dont on veut calculer la racine carré) au tmpi et maitre le résultat dans tmpi+2. Ça permet de comparer le résultat obtenu à la source.
4. SI le résultat est supérieur à 0 on termine le processus (aller à fin).
5. Sino générer le carré de tmpi et le maitre dans tmpi+2.
6. Comparer à nouveau ce résultat avec la source.
7. Si (résultat\*résultat> src) allez à 10.
8. Sino ajouter la précision au résultat (tmpi ) .
9. Et refaire à nouveau le processus (allez à 3).
10. Soustraire la précision du résultat et terminer le processus.
11. Fin.

1	= 0 tmpi
2	=0.0001 tmpi+1
3	-tmpi src tmpi+2
4	JG 12
5	*tmpi tmpi tmpi+2
6	-tmpi+2 src tmpi+2
7	JG 10
8	+ tmpi tmpi+1 tmpi
9	JMP 3
10	-tmpi tmpi+1 tmpi
12	Fin

La variance :

```
case 5:
    $$=Variance($3.values,$3.cpt);
break;
```

Voici la formule utilisé pour calculer la variance :

$$\text{variance}(n1,n2,...,n)=(\text{carré}(n1-\text{moy}(n1..n))+\text{carré}(n2-\text{moy}(n1..n))+...)/n-1.$$

- Calculer la moyenne des éléments de la liste.
- Générer un tmpi initialiser à 0 qui va contenir le résultat du calcul de la variance.

Op	Source1	Source2	Destination
=	0	#	tmpi

- Parcourir la liste et pour chaque élément faire :
  - Soustraire la moyenne des élément (tmpi) de cet élément de la liste et mettre le résultat dans tmpi+1.

Op	Source1	Source2	Destination
-	Values[i]	tmpmoy	tmpi+1

- Calculer le carré de ce résultat et le mettre dans tmpi+1.

Op	Source1	Source2	Destination
*	tmpi+1	tmpi+1	tmpi+1

- Ajouter ce résultat au tmpi.

Op	Source1	Source2	Destination
+	tmpi	tmpi+1	tmpi

- Diviser le résultat par le nombre d'élément de la liste (comme le cpt commence par 0 donc on divise par cpt au lieu de cpt-1).

Op	Source1	Source2	Destination
/	tmpi	cpt	tmpi

- Retourner le tmpi (\$\$=tmpi).

Voici la fonction qui permet de générer les Quads de cette opération :

```
char* Variance( char* values[15],int cpt) {  
    Moy(values,cpt);  
    Tmps[cptTmps].name=malloc(12); //tmp3  
    sprintf(Tmps[cptTmps].name,"tmp%d",cptTmps+1);  
    WriteQuad("=", "0", "#", Tmps[cptTmps].name);  
    Tmps[cptTmps+1].name=malloc(12); //tmp4  
    sprintf(Tmps[cptTmps+1].name,"tmp%d",cptTmps+2);  
    for (int j=0; j<cpt; j++)  
    {  
        WriteQuad("-", values[j], Tmps[cptTmps-2].name, Tmps[cptTmps+1].name);  
        WriteQuad("*", values[j], Tmps[cptTmps+1].name, Tmps[cptTmps+1].name);  
        WriteQuad("+", Tmps[cptTmps+1].name, Tmps[cptTmps].name, Tmps[cptTmps].name);  
    }  
    char * tmp=malloc(12);  
    sprintf(tmp,"%d",cpt);  
    WriteQuad("/", Tmps[cptTmps].name, tmp, Tmps[cptTmps].name);  
    free(tmp);  
    cptTmps=cptTmps+2;  
    return Tmps[cptTmps-2].name;  
}
```

L'écart type :

```
case 6:  
    $$=ecrt($3.values,$3.cpt);  
break;
```

- Calculer la variance des éléments de la liste.
- Puis calculer racine carrée des résultats de la variance et retourner le résultat.

Voici la fonction qui permet de générer les Quads de cette opération :

```
extern char* ecrt( char* values[15],int cpt){  
    //return (sqrt(Var( values,cpt)));  
    Variance(values,cpt);  
    Sqrt(Tmps[cptTmps-2].name);  
    return Tmps[cptTmps-3].name;  
}
```

Max :

```
case 4:  
    $$=Max($3.values,$3.cpt);  
break;
```

L'évaluation :

- Générer un  $tmp_i$  qui va contenir la valeur du max initier avec le premier élément du tableau « values ».
- Générer un  $tmp_{i+1}$  qui va contenir la valeur de l'élément  $i$  de la table « values ».
- Générer un  $tmp_{i+2}$  qui va contenir le résultat de soustraction de  $tmp_{i+1}$  au  $tmp_i$ .
- Pour chaque élément de la liste faire :

1. Affecter l'élément  $i$  de la list ( $values[i]$ ) au  $tmp_{i+1}$ .
2. Soustraire la valeur de  $tmp_{i+1}$  du contenue de  $tmp_i$  (Pour comparer  $values[i]$  avec le max).
3. Si la valeur du max est supérieure à la valeur l'élément  $i$  de la table Allez à 1.
4. Sino affecter la valeur l'élément  $i$  de la table au max.

1	= values[i] tmp <sub>i+1</sub>
2	-tmp <sub>i</sub> tmp <sub>i+1</sub> tmp <sub>i+2</sub>
3	JG 1
4	= tmp <sub>i</sub> tmp <sub>i+1</sub>

Voici la fonction qui permet de générer les Quads de cette opération :

```
extern char *Max(char* values[50],int cpt)
{
    int i=0;
    Tmps[cptTmps].name=malloc(12);
    sprintf(Tmps[cptTmps].name,"tmp%d",cptTmps+1);
    WriteQuad("=",values[i],"#",Tmps[cptTmps].name); //tmp1 contien la valeur du max
    Tmps[cptTmps+1].name=malloc(12);
    sprintf(Tmps[cptTmps+1].name,"tmp%d",cptTmps+2);
    Tmps[cptTmps+2].name=malloc(12);
    sprintf(Tmps[cptTmps+2].name,"tmp%d",cptTmps+3);
    for (i=1;i<cpt;i++)
    {
        WriteQuad("=",values[i],"#",Tmps[cptTmps+1].name); // = tab[i] tmp2
        WriteQuad("-",Tmps[cptTmps].name,Tmps[cptTmps+1].name,Tmps[cptTmps+2].name); //Sub tmp1 tmp2 tmp3

        WriteQuad("Load",Tmps[cptTmps+2].name,"#","#");
        char *tmp=malloc(12);
        sprintf(tmp,"%d",NumLine+3); //il faut jumper a =[i] tmp2
        WriteQuad("JG","#","#",tmp);
        WriteQuad("=",Tmps[cptTmps+1].name,"#",Tmps[cptTmps].name); // = tmp2 tmp1
        free(tmp);
    }
    cptTmps=cptTmps+3;
    return Tmps[cptTmps-3].name;
}
```

*Min :*

C'est le même principe que le « Max » sauf qu'ici on fait le jump si la valeur du max est inférieure à la valeur de l'élément  $i$  de la table values.

## L'évaluation :

Dans cette partie optionnelle on va interpréter le code intermédiaire ce qui permet de l'exécuter afin d'avoir le résultat de l'expression donné au départ :

Le principe ici est de lire le fichier « out » qui contient le code intermédiaire et de l'interpréter ligne par ligne. On divise chaque ligne en quatre champs ce qui permet de régénérer le Quadruplet et puis analyser chaque champ du Quadruplet et effectuer le traitement nécessaire.



L'évaluation :

Exemple de fonction d'interprétation :

Affectation :

```
else if (strcmp(array[0], "=") == 0)
{
    EvaluateAff(array[1], array[3]);
    i++;
}
```

Si le champ d'opération est le symbole « = » et donc l'affectation à ce moment-là on effectue au champs destination la valeur de la source si la destination est un tmp; donc on affecte la valeur de la source au champ valeur du ième élément de la table du tmp. Sino on cherche la variable et on affecte la valeur de la source au champ valeur de cette variable. Voici la fonction qui permet de faire ça :

```
extern void EvaluateAff(char *src, char * dest)
{
    float num1 = getValueVar(src);
    int index = getIndexVar(dest);
    if (strstr(dest, "tmp") != NULL) {
        Tmps[index].value = num1;
    }
    else
    {
        IDs[index].value = num1;
    }
}
```

Addition :

```
if (strcmp(array[0], "+") == 0)
{
    EvaluateAdd(array[1], array[2], array[3]);
    i++;
}
```

Dans le cas de l'addition on récupère la valeur du deux champs source et on effectue l'addition puis on affecte le résultat à la destination. Voici la fonction qui permet de faire ça :

```
void EvaluateAdd(char *a, char *b, char * dest)
{
    float num1 = getValueVar(a);
    float num2 = getValueVar(b);
    int index = getIndexVar(dest);
    Tmps[index].value = num1 + num2;
}
```

Les autres opérations arithmétiques tel la soustraction, multiplication suit exactement le même principe. Pour l'opération du moins unaire on considère pas le 2<sup>ème</sup> champ de la source et on retourne directement -source1.

JZ :

L'évaluation :

```
else if (strcmp(array[0], "JZ")==0)
{
    indexLine= EvaluateJZ(LoadValue,array[3]);
    if( indexLine!=-1)
        i=i+1; //cause i begin with 0
    else
        i=indexLine-1; /*we jump to the given line and because
        it start from 0 so we sub 1*/
}
```

Dans ce cas on évalue la valeur de la source si celle-ci égale à 0 en jump ver la valeur de la destination sino on lit la ligne suivante du fichier. Voici la fonction qui permet cette évaluation :

```
extern int EvaluateJZ(float a,char *dest)
{
    int indexLine=0;
    if (a==0)
        indexLine=atoi(dest);
    else
        indexLine=-1;
    return indexLine;
}
```

JMP :

C'est le même principe que JZ sauf que dans ce cas on fait aucune évaluation de la source mais on jump directement à la destination.

JG :

C'est le même principe que JZ sauf que dans celle-ci on fait le Jump au cas où la valeur est supérieure à 0.

JL :

C'est l'inverse du JG.

Load :

On a ajouté cette directive dans notre Tp surtout pour nous aider dans l'opération de puissance la ou on doit comparer la base avec « 0 » et donc utilisé le JZ.

```
else if (strcmp(array[0], "Load")==0)
{
    LoadValue=EvaluateLoad(array[1]);
    i++;
}
```

Le traitement de « load » est très simple, on a qu'à récupérer la valeur de la source et l'affecter à une variable globale LoadValue afin de l'utiliser après pour les JZ. Voici la fonction qui permet cette évaluation :

```
extern float EvaluateLoad(char *src)
{
    return (getValueVar(src));
}
```

L'évaluation :

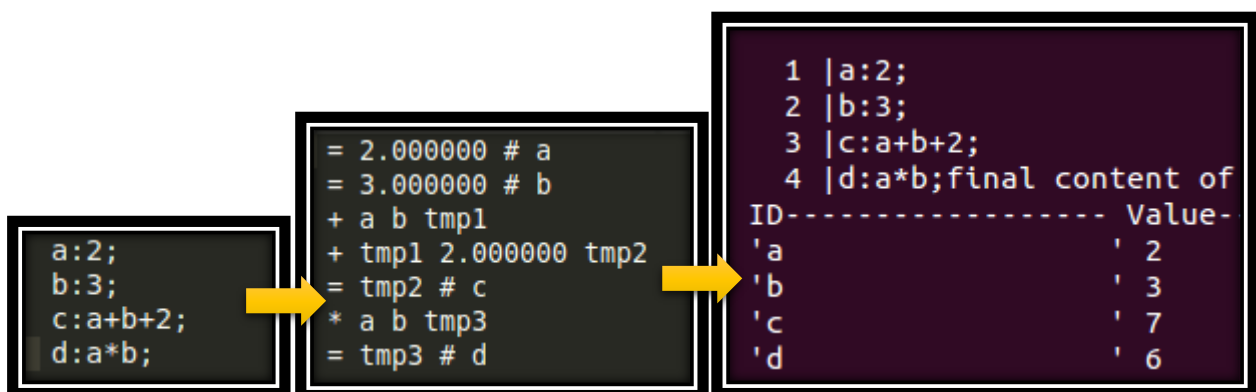
Le résultat de cette interprétation est l'exécution du code intermédiaire et donc retourner le résultat de l'expression donné au départ.

### Exemple de code intermédiaire et d'évaluation :

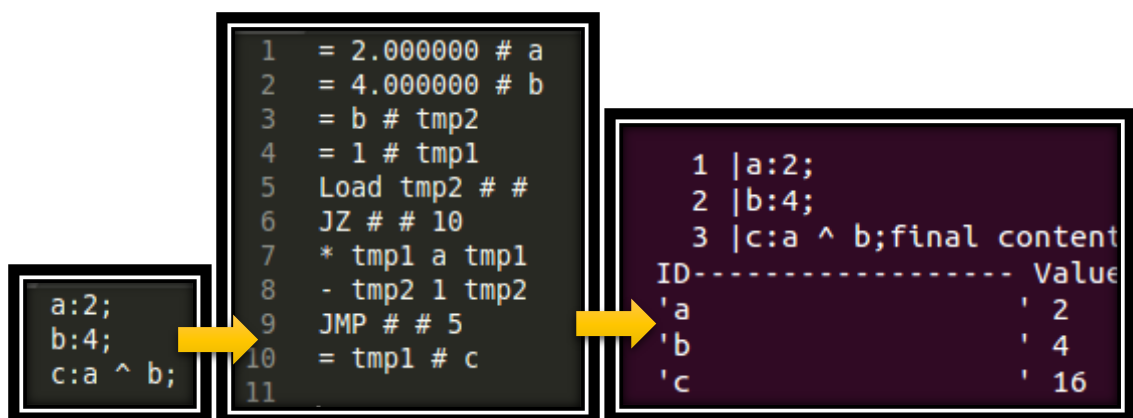
Ici on simule un vraie compléter donc il faut initier toutes les variables à l'avance. On ajoute quelque variable qui va contenir le résultat de chaque expression et ceci dans le but d'afficher le résultat final :

Le premier cadre contient l'expression du départ, le 2<sup>ème</sup> cadre contient le code intermédiaire et enfin le cadre le plus à droite contient le résultat de l'exécution :

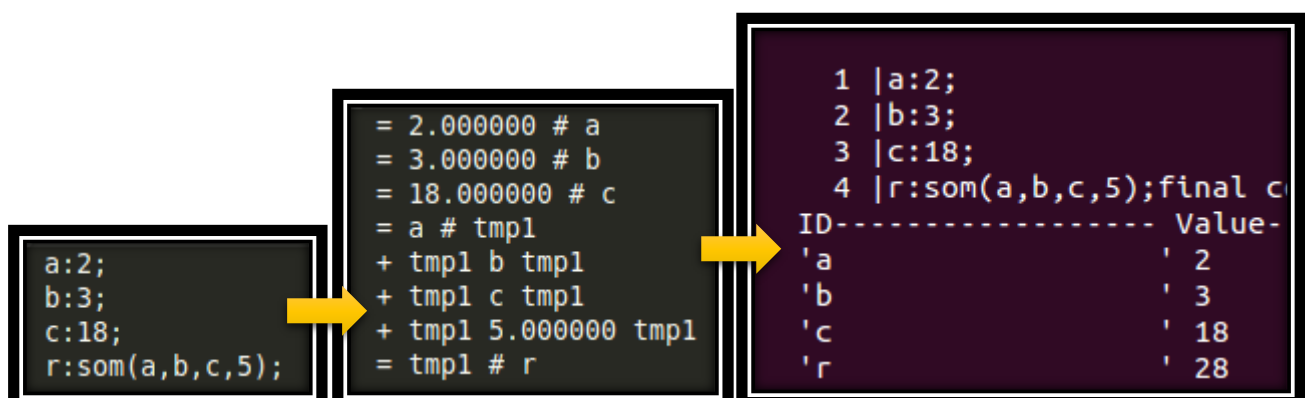
Fonctions de base :



Puissance :

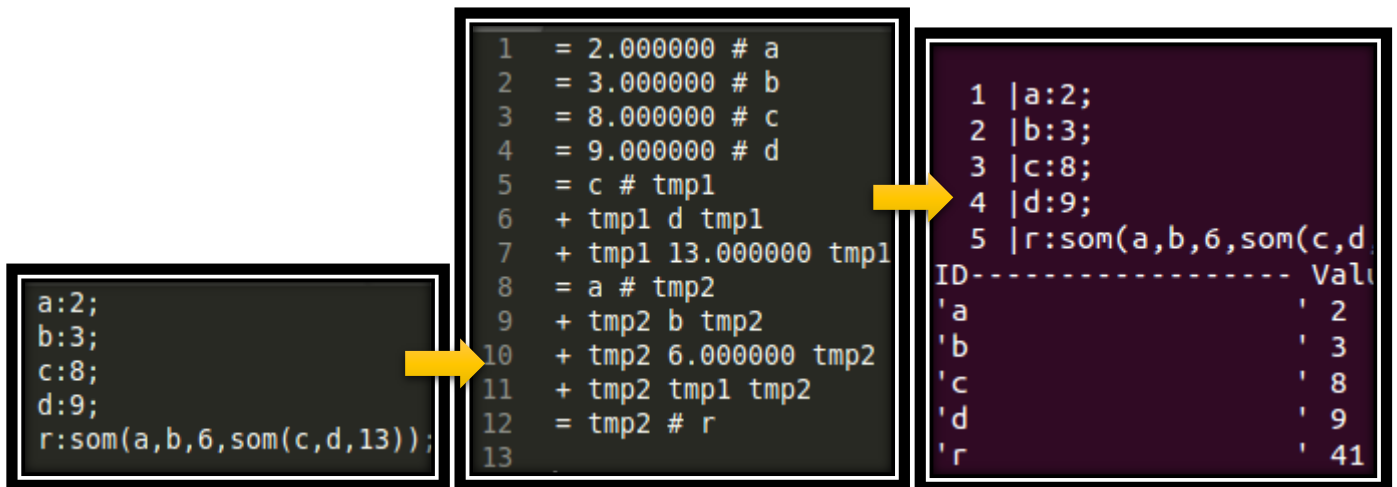


Somme :

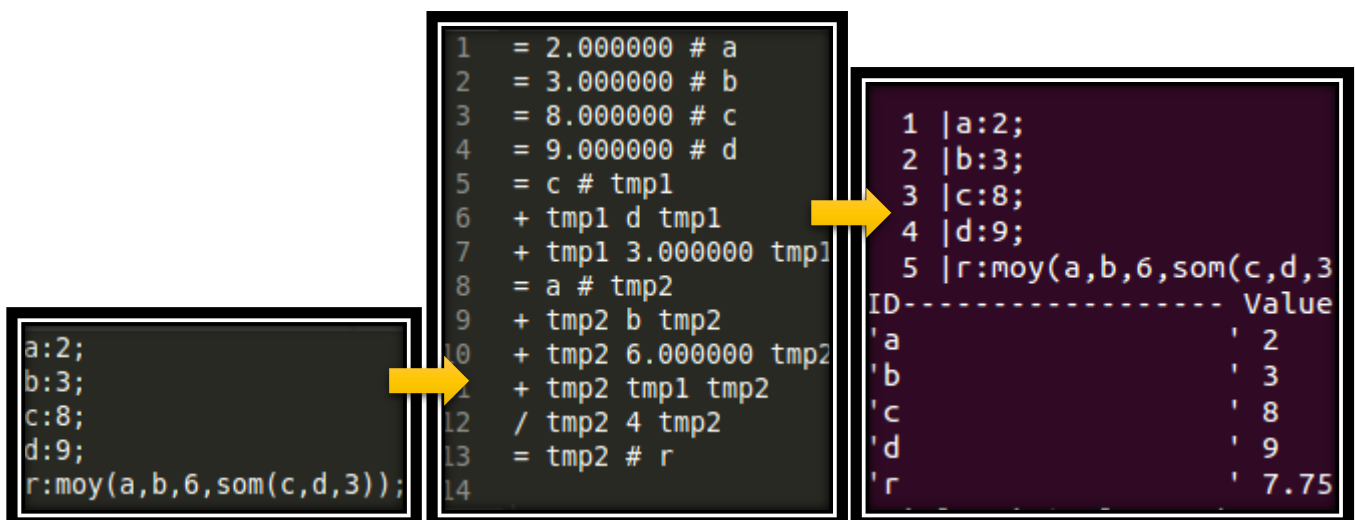


L'évaluation :

Somme imbriqué :

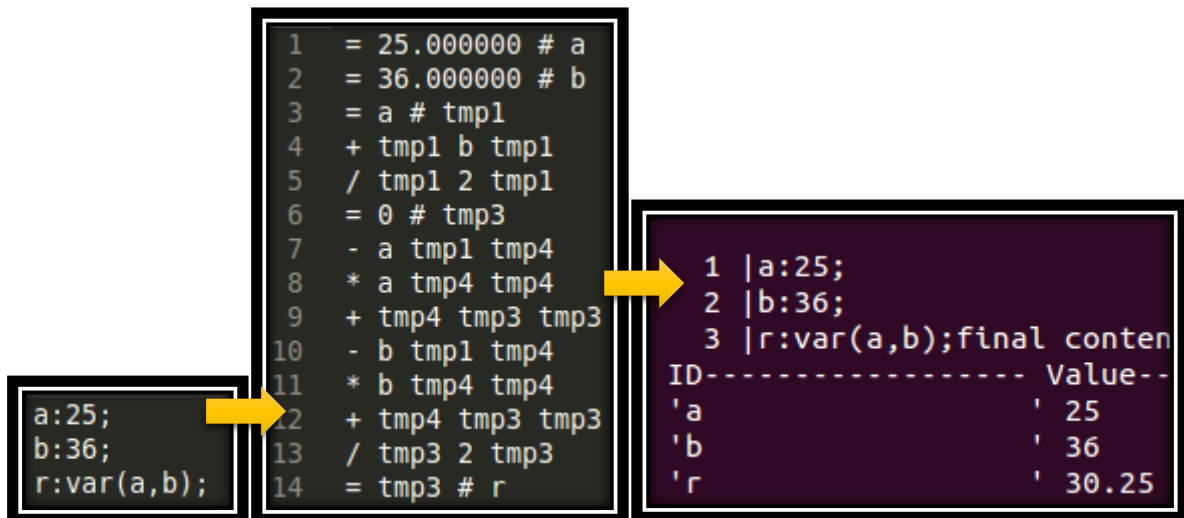


Moyenne pondérée :

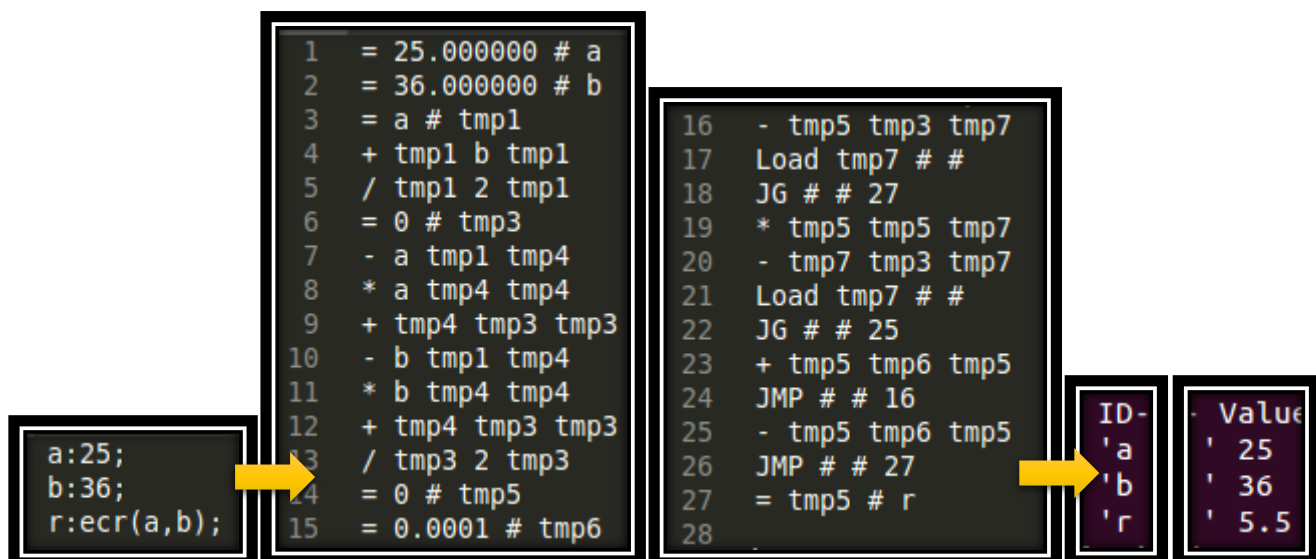


L'évaluation :

Variance :

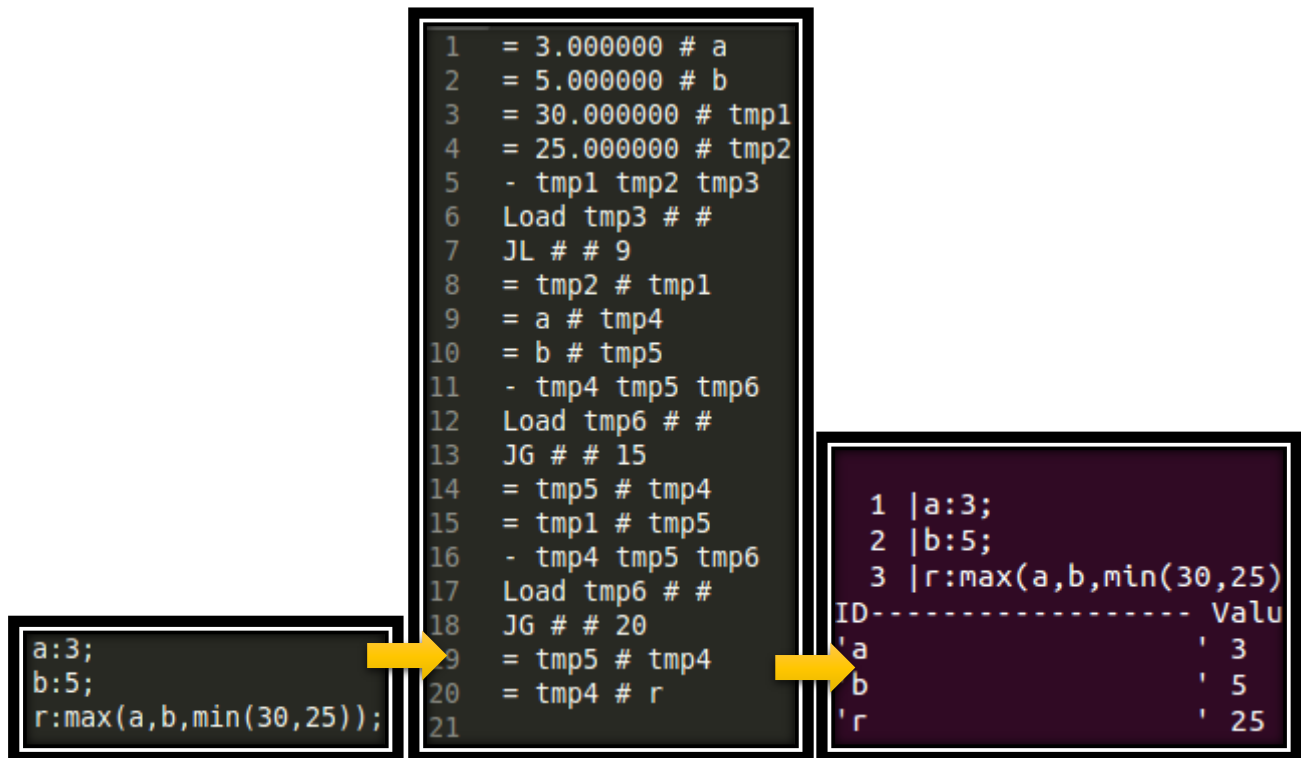


Ecart type :

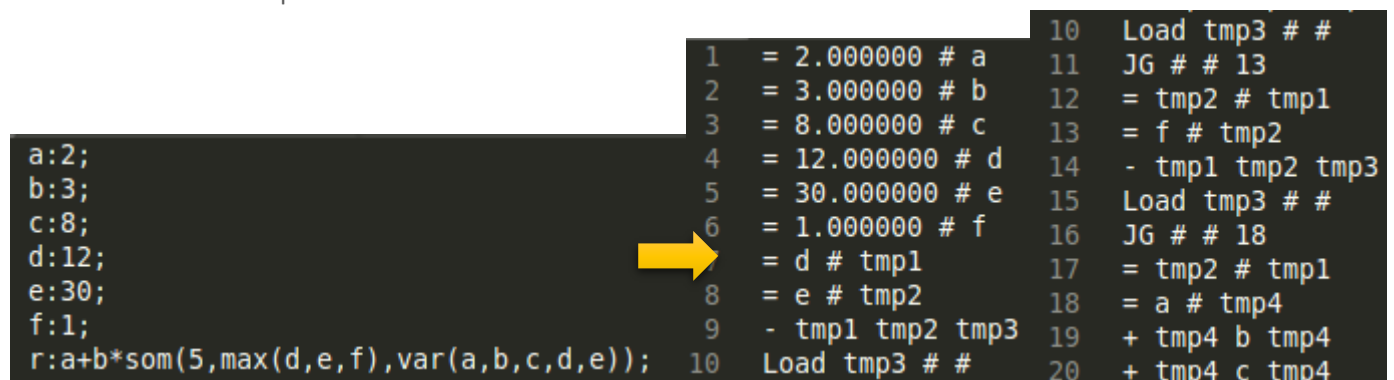


L'évaluation :

Max Min :



Autre exemple :



L'évaluation :

```
21 + tmp4 d tmp4
22 + tmp4 e tmp4
23 / tmp4 5 tmp4
24 = 0 # tmp6
25 - a tmp4 tmp7
26 * a tmp7 tmp7
27 + tmp7 tmp6 tmp6
28 - b tmp4 tmp7
29 * b tmp7 tmp7
30 + tmp7 tmp6 tmp6
31 - c tmp4 tmp7
32 * c tmp7 tmp7
33 + tmp7 tmp6 tmp6
```

```
34 - d tmp4 tmp7
35 * d tmp7 tmp7
36 + tmp7 tmp6 tmp6
37 - e tmp4 tmp7
38 * e tmp7 tmp7
39 + tmp7 tmp6 tmp6
40 / tmp6 5 tmp6
41 = 5.000000 # tmp8
42 + tmp8 tmp1 tmp8
43 + tmp8 tmp6 tmp8
44 * b tmp8 tmp9
45 + a tmp9 tmp10
46 = tmp10 # r
```

```
1 |a:2;
2 |b:3;
3 |c:8;
4 |d:12;
5 |e:30;
6 |f:1;
7 |r:a+b*som(5,max(d,e,f),
ID----- Value--
'a          ' 2
'b          ' 3
'c          ' 8
'd          ' 12
'e          ' 30
'f          ' 1
'r          ' 416.6
```

# Conclusion

Ce Tp nous a vraiment permet de comprendre le fonctionnement d'un compilateur tout en générant le code qui permet l'évaluation et la génération d'une forme intermédiaire d'une expression arithmétique, et aussi de comprendre comment serai interpréter le code intermédiaire en faisant la partie optionnelle. Ce tp a également ouvert notre esprit à d'autre outils tel Flex et Bison.



# Bibliographie

- Christian Hagen. Better error handling using Flex and Bison, developerWorks.
- Site web [www.labri.fr](http://www.labri.fr), article : « Qu'est-ce qu'un compilateur ? Trois étapes importante », lien : <http://www.labri.fr/perso/zeitoun/enseignement/archive/topics/Compilation/01-02/Transparents-2x2-Compilation.pdf>.
- Ait-Aoudia, S., (2017), chapitre 0\_Introduction\_aux\_Compilateurs, page 6.
- Ait-Aoudia, S., (2017), chapitre 5\_Traduction-Dirigée-Syntaxe.